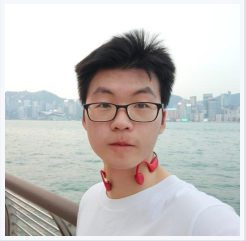
研究简历 LLMs & AGENTS

蒋卓航 Zhuohang Jiang

大语言模型·智能体·多模态 RAG ·推理评测

(+86) 152-6704-1093 | zhuohang.jiang@connect.polyu.hk
zhuohangjiang.com | GitHub: jzzzzh | Google Scholar



研究概况

研究聚焦**大模型推理、多模态 RAG 与自进化智能体**。已发表/录用 **8 篇成果**，其中按 CCF-A 会议及相关 track 口径计 **7 篇，一作/共同一作 5 篇**，覆盖 KDD、CVPR、NeurIPS、AAAI。

教育背景

香港理工大学｜计算机科学博士研究生 2024.09 – 至今
导师：李青教授、范文琦教授；GPA：**3.60/4.00**。

四川大学｜计算机科学与技术，工学学士 2020.09 – 2024.06
专业 GPA：**3.79/4.00**；综合 GPA：3.78/4.00。

工业经历

快手科技·电商短视频中心｜研究实习生 2025.10 – 至今

- 研发 **AB Agent**：将历史策略/代码改动、参数及指标结果对齐为可检索策略单元；接入 A/B 平台，自动对比实验、输出调参建议，执行配置校验与审核。线上 **GMV +4.829%**，各项护栏正向，成功/失败经验持续回写。
- 研发 **AIR**，将大模型生成的语义意图分解为可缓存、可组合的原子知识，以在线检索近似序列级语义推理，降低实时调用成本；方法及落地结果见下方论文。

代表作

HiBench ｜大语言模型层次结构推理评测

第一作者 / 项目负责人·KDD 2025 Benchmark & Dataset Track

设计与实现：负责 benchmark 设计与代码统筹；控制树深度、宽度和节点数，实现**树/JSON/公式生成、算法标答与统一提示**，并纳入代码和论文任务（**30 项任务、39,519 条样例**）。**评测与训练：**对 **10 个家族的 20 个 LLM** 开展结构表示、复杂度和 CoT 对比；构造指令微调数据，使 Llama-3.1-8B、Qwen2.5-7B 平均相对提升 **88.84%、31.38%**，开源数据与模块化工具库。

SUPERGLASSES / SUPERLENS ｜智能眼镜多模态评测与智能体

第一作者·CVPR 2026 Findings

数据：基于真实眼镜设备构建 **2,422 个问答对、14 个领域、8 类问题**，保留工具调用轨迹。**智能体：**领域路由判断直接回答或触发 RAG；开放词汇检测定位小目标，多跳问题拆为单跳子查询，再进行图像/文本搜索、HTML 清洗与证据分块重排。采用**两级 Redis 缓存**复用“查询到 URL、URL 到正文”结果。评测 **26 个模型/RAG 变体**；基于 Qwen2.5-VL-7B 的 SUPERLENS 得分由 **32.82 提至 44.10（+11.28 分）**。

A/B Agent ｜面向工业 A/B 测试策略迭代的自进化智能体

第一作者·arXiv:2608.04625，2026（预印本）

检索与生成：按业务域、场景、排序阶段与优化目标组织经验树；融合**稀疏/稠密检索**，按树路径邻近程度加权，再用 **Qwen-Reranker** 精排；生成附历史证据的策略配置，并检查工程可行性与护栏风险。**自进化：**以实验树节点记录策略、参数、指标及上下文，进行**父子版本与兄弟分支对比**；结合置信度加权收益和护栏损失惩罚，决定在有效参数区间局部搜索，或在收益停滞时切换策略分支。

AIR ｜大模型原子意图推理与离在线解耦

第一作者·KDD 2026 Applied Data Science Track

大模型推理：将行为、用户属性与对象描述输入 LLM，生成分层语义意图路径，离线存储为可复用原子知识。**检索组合：**在线按行为权重与时间衰减构建意图树，检索目标相关意图链并以**多头注意力**融合证据，近似序列级语义推理，无需实时调用 LLM；实现约 **400× 吞吐提升**，电商落地 **GMV +3.446%**。

QA-Dragon ｜查询感知的动态多模态 RAG 视觉问答系统

第一作者·KDD Cup 2025 Workshop on Multimodal Retrieval Augmented Generation

将初始答案路由至**直接输出、搜索验证或 RAG**；按知识缺口选择图像/文本工具，裁剪问题相关目标进行图像检索，重排证据后生成并校验答案；单源/多源/多轮任务较基线分别提升 **5.06% / 6.35% / 5.03%**。

学术活动、荣誉与技能

学术与荣誉：KDD 2025 Reasoning Day 受邀报告；KDD Cup 2025 CRAG-MM 全球第 12 名（队长）；NeurIPS 2024 Spotlight（共同一作）。
技能：PyTorch、Hugging Face、RAG、智能体系统、Docker、Git；中文（母语）、英语（IELTS 6.5）。