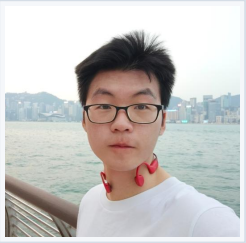
蒋卓航 Zhuohang Jiang

大语言模型·智能体·多模态 RAG ·推理评测

(+86) 152-6704-1093 | zhuohang.jiang@connect.polyu.hk
zhuohangjiang.com | GitHub: jzzzzh | 微信: zhuohangjiang



研究概况

研究聚焦**大模型推理、多模态 RAG 与自进化智能体**。已发表/录用 **8 篇成果**，其中按 CCF-A 会议及相关 track 口径计 **7 篇，一作/共同一作 5 篇**，覆盖 KDD、CVPR、NeurIPS、AAAI。累计引用 **633 次**，h 指数 **7**。

教育背景

香港理工大学｜计算机科学博士研究生 2024.09 – 至今
导师：李青教授、范文琦教授；GPA：**3.60/4.00**。

四川大学｜计算机科学与技术，工学学士 2020.09 – 2024.06
专业 GPA：**3.79/4.00**；综合 GPA：3.78/4.00。

工业与开源经历

快手科技·电商短视频中心｜研究实习生 2025.10 – 至今

- 研发 **AB Agent**：将历史策略/代码改动、参数及指标结果对齐为可检索策略单元；接入 A/B 平台，自动对比实验、输出调参建议，执行配置校验与审核。线上 **GMV +4.829%**，各项护栏正向，成功/失败经验持续回写。
- 研发 **AIR**，将大模型生成的语义意图分解为可缓存、可组合的原子知识，以在线检索近似序列级语义推理，降低实时调用成本；方法及落地结果见下方论文。

Textus ｜项目合伙人 GitHub 580 Stars
负责 Textus 的**写作 Agent 功能开发**，接入在线/本地大模型，实现智能续写、语法修正、逐句修改建议与审阅批注，将大模型能力融入 Markdown 写作流程。

代表作

[KDD'25] HiBench ｜大语言模型层次结构推理评测
第一作者 / 项目负责人·KDD 2025 Benchmark & Dataset Track
背景：现有评测偏重平面结构，缺少对层次依赖与隐式结构的系统检验。**方法：**负责 benchmark 设计与代码统筹，实现可控树/JSON/公式生成、算法标答及代码/论文任务（**30 项任务、39,519 条样例**）；对 **10 个家族的 20 个 LLM** 开展结构表示、复杂度与 CoT 对比，并构造指令微调数据。**效果：**揭示结构修改与隐式层次推理短板；微调使 Llama-3.1-8B、Qwen2.5-7B 平均相对提升 **88.84%、31.38%**，开源数据/工具库。

[CVPR'26] SUPERGLASSES / SUPERLENS ｜智能眼镜多模态评测与智能体
第一作者·CVPR 2026 Findings
背景：传统 VQA 忽略眼镜广视野下的小目标定位与外部知识需求，检索易偏离关注对象。**方法：**构建 **2,422 个真实设备问答对、14 个领域、8 类问题**；按需切换直接回答/RAG，经目标定位、问题拆解、图文搜索、HTML 清洗与证据重排生成答案，以**两级 Redis 缓存**复用搜索/网页解析。**效果：**评测 **26 个模型/RAG 变体**；SUPERLENS 将 Qwen2.5-VL-7B 得分从 **32.82 提至 44.10（+11.28 分）**。

A/B Agent ｜面向工业 A/B 测试策略迭代的自进化智能体
第一作者·arXiv:2608.04625，2026（预印本）
背景：平铺检索难以复用分散的历史实验知识，缺少连续实验反馈调参机制。**方法：**构建经验树，融合**稀疏/稠密检索、树路径加权与 Qwen-Reranker**，生成附证据配置；通过实验树**父子/兄弟版本对比**，结合置信度与护栏惩罚，选择局部调参/切换分支并回写经验。**效果：**线上部署 **GMV +4.829%**，各项护栏指标均保持正向收益。

[KDD'26] AIR ｜大模型原子意图推理与离在线解耦
第一作者·KDD 2026 Applied Data Science Track
背景：LLM 调用成本高，难以实时处理多变、冗长且含噪的行为序列。**方法：**用 LLM 将行为/用户/对象上下文离线转为原子意图路径并缓存；在线按行为权重/时间衰减组合意图树，检索目标相关意图链，以**多头注意力**融合证据，近似序列级语义推理，无需实时调用 LLM。**效果：**相较实时 LLM 调用实现约 **400× 吞吐提升**，电商落地 **GMV +3.446%**。

[KDD'25] QA-Dragon ｜查询感知的动态多模态 RAG 视觉问答系统
第一作者·KDD Cup 2025 Workshop on Multimodal Retrieval Augmented Generation
背景：固定检索难以适配 VQA 中视觉识别与外部事实核验的不同需求。**方法：**路由初始答案至**直接输出/搜索验证/RAG**，选择图文工具、裁剪目标，重排证据并校验答案。**效果：**单源/多源/多轮任务较基线分别提升 **5.06% / 6.35% / 5.03%**。

学术活动、荣誉与技能

学术与荣誉：KDD 2025 Reasoning Day 受邀报告；KDD Cup 2025 CRAG-MM 全球第 12 名（队长）；NeurIPS 2024 Spotlight（共同一作）。
技能：PyTorch、Hugging Face、RAG、智能体系统、Docker、Git；中文（母语）、英语（IELTS 6.5）。